Задание 3. Композиции алгоритмов для решения задач регрессии

Бикметов Данил, 317 группа

Декабрь, 2020

Введение

В практическом задании были реализованы собственные методы RandomForest и GradientBoosting. Экспериментальная часть задания проводилась на датасете данных о продажах недвижимости.

Практическая часть

Для начала сделаем константное предсказание средним и посчитаем ошибку: $Baseline\ RMSE = 361.469$. Это поможет нам понять масштаб ошибки предсказания в дальнейшем. Теперь перейдём к экспериментам со случайным лесом и градиентным бустингом.

Исследование поведения алгоритма случайный лес

В этом разделе мы изучим зависимость $RMSE$ на отложенной выборке и время работы алгоритма в зависимости от следующих параметров:

- количество деревьев
- размерность подвыборки признаков для одного дерева
- максимальная глубина дерева (+ случай, когда глубина неограниченна)

1. Количество деревьев

Изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от количества деревьев. Изобразим зависимость на графике:

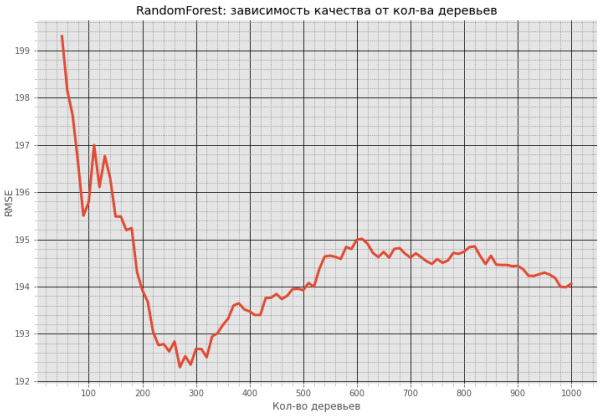

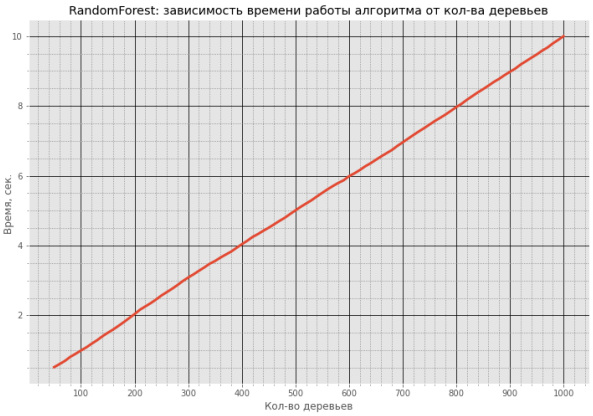

С ростом количества деревьев качество алгоритма на отложенной выборке растёт, но не монотонно. В целом с увеличением количества деревьев качество улучшается, однако оптимальным можно назвать параметр в 150-200 деревьев, поскольку ошибка получается сравнительно небольшой, зато алгоритм работает существенно быстрее. Время работы алгоритма растёт линейно с ростом количества деревьев.

2. Размерность подвыборки признаков для одного дерева

Теперь изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от размера признакового пространства подвыборок.

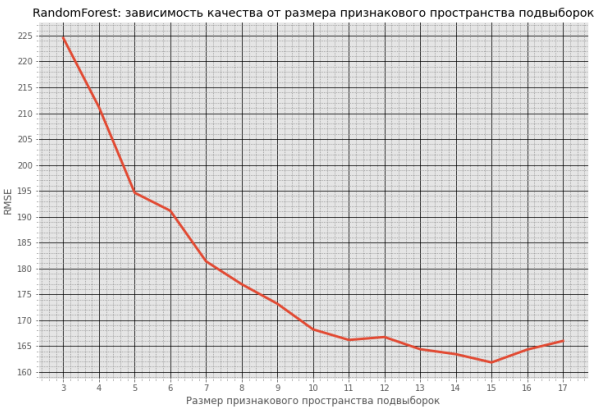

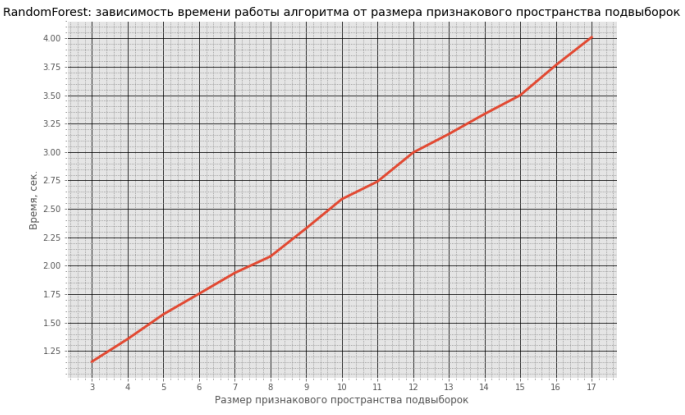

Чем больше признаковое пространство деревьев, тем выше качество алгоритма. В данном случае это можно связать с тем, что общее количество признаков небольшое (всего 17). Однако оптимальный результат достигается при 15 признаках. Время работы алгоритма растёт линейно с ростом числа признаков в подвыборках.

3. Максимальная глубина дерева

Изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от глубины деревьев. Предварительно заметим, что глубину каждого дерева можно неограничивать вовсе. Отдельно посчитаем $RMSE$ для неограниченной глубины деревьев и укажем её на графике константной желтой линией для сравнения.

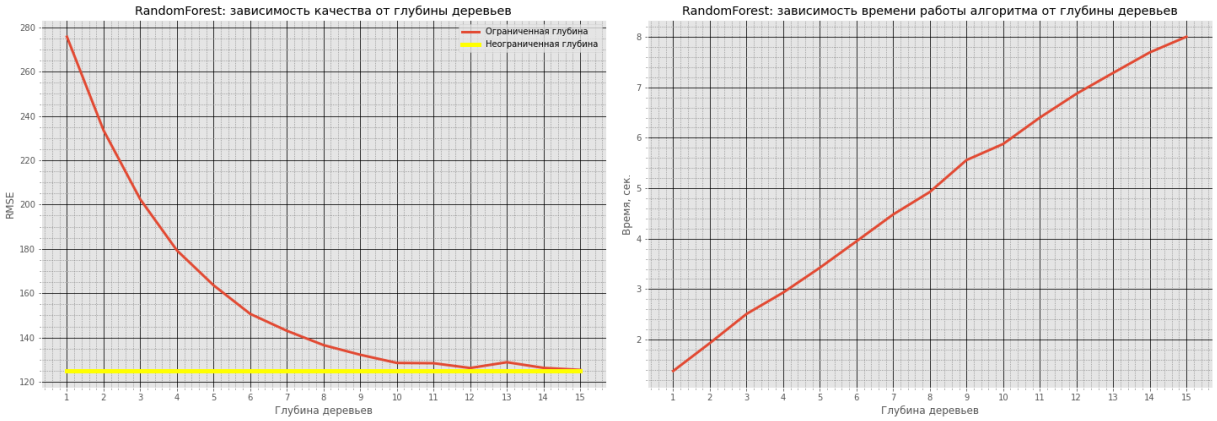

Качество алгоритма улучшается с увеличением глубины деревьев. С небольшой погрешностью можно сказать, что ошибка алгоритма с ростом глубины деревьев асимптотически стремится к ошибке алгоритма с неограниченными деревьями. Время работы алгоритма растёт линейно. Важно отметить, что время работы алгоритма в случае неограниченной глубины деревьев составило 9.83 секунды, что примерно соответствует глубине 20.

Исследование поведения алгоритма градиентного бустинга

В этом разделе мы изучим зависимость $RMSE$ на отложенной выборке и время работы алгоритма в зависимости от следующих параметров:

- количество деревьев
- размерность подвыборки признаков для одного дерева
- максимальная глубина дерева (+ случай, когда глубина неограниченна)
- выбранный $learning\_rate$

1. Количество деревьев

Изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от количества деревьев. Изобразим зависимость на графике:

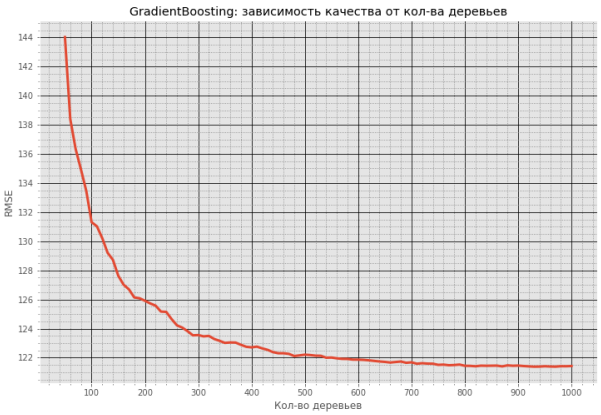

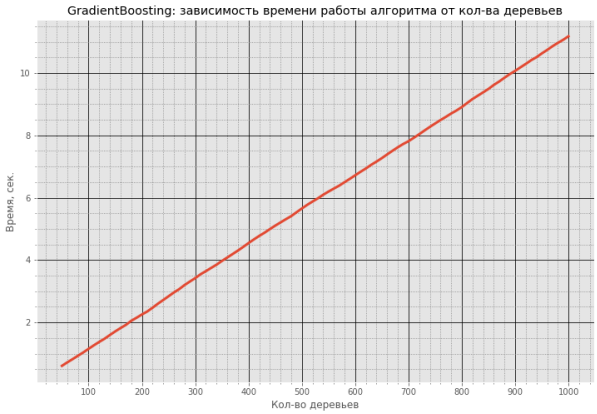

В данном случае очевидно, что с ростом количества деревьев ошибка монотонно снижается. Это согласуется с интуицией, поскольку с каждой итерацией алгоритм находит всё лучшее приближение. Время работы алгоритма растёт линейно с ростом числа деревьев.

2. Размерность подвыборки признаков для одного дерева

Теперь изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от размера признакового пространства подвыборок.

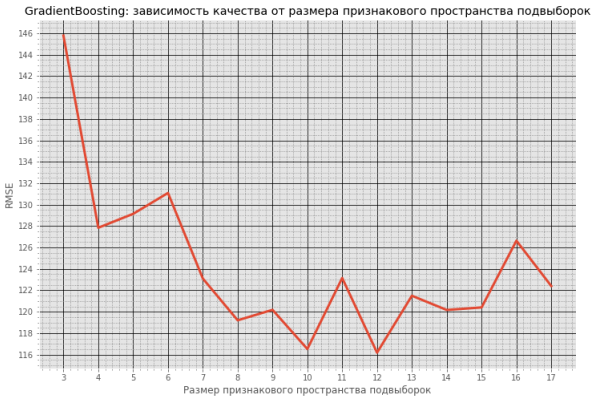

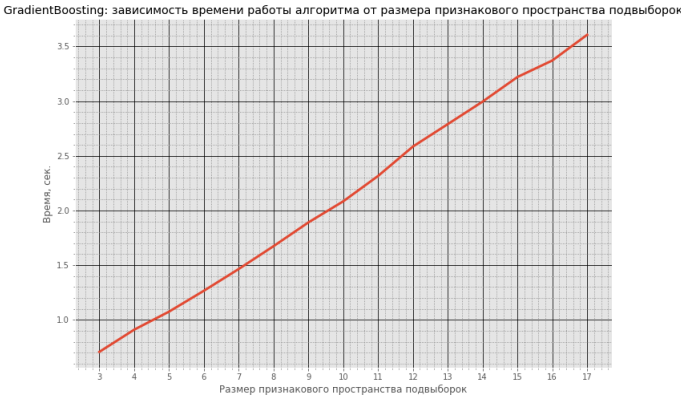

В этом случае результат не так очевиден: прослеживается своеобразная "яма"в середине графика, а оптимальное значение ошибки достигается при 12 признаках. В нашем случае сложно делать какие либо выводы, поскольку общее количество признаков невелико. Время работы алгоритма растёт линейно с ростом размера признакового пространства деревьев.

3. Максимальная глубина дерева

Изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от глубины деревьев. Как и в случае с RandomForest, глубину каждого дерева можно неограничивать вовсе. Поэтому отдельно посчитаем $RMSE$ для неограниченной глубины деревьев и укажем её на графике константной желтой линией для сравнения.

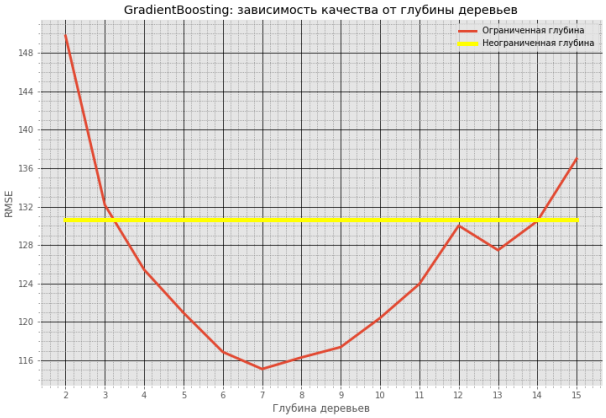

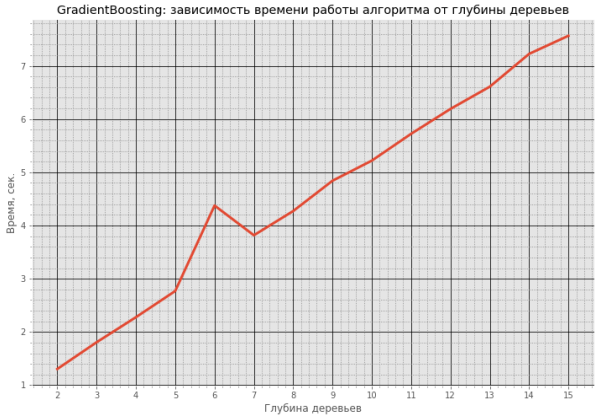

Оптимальная глубина - 7. При дальнейшем увеличении глубины ошибка алгоритма растёт. Следовательно, при неограниченной глубине качество должно получиться сравнительно низким, что мы и видим на графике. Время работы алгоритма растёт линейно с ростом максимальной глубины, а скачок на графике вызван скорее техническими деталями, чем теоретическими. Время работы алгоритма в случае неограниченной глубины деревьев равно 10 секундам, что соответствует глубине 20, если продолжить линейную функцию на втором графике.

4. Темп обучения

Наконец, изучим зависимость RMSE на отложенной выборке и время работы алгоритма в зависимости от выбора *learning_rate*.

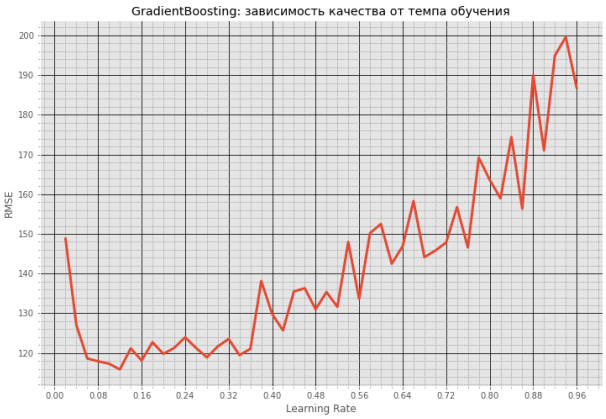

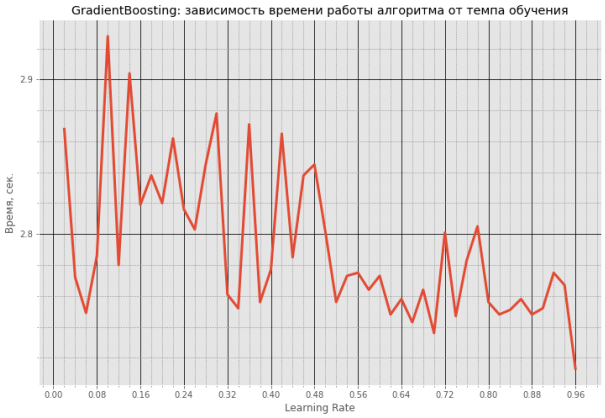

Ошибка минимальная при небольших *learning_rate* от 0.08 до 0.12. При дальнейшем увеличении парамера качество падает. Нет гладкой зависимости времени работы алгоритма от *learning_rate*, хотя при значениях параметра, близких к единице, алгоритм завершается немного быстрее. Однако отличие составляет всего одну десятую секунды, поэтому говорить о прямой зависимости нельзя.

Пару слов о реализации сервера

К заданию был реализован сервер на Flask, с помощью которого пользователь, не знающий Machine Learning, имеет возможность обучить модель и получить предсказание. На сервере имеется возможность выбирать алгоритм, менять гиперпараметры, следить за обучением. Удалось реализовать следующие возможности:

- Файлы на сервер загружаются с помощью формы *input* типа $file$. Для этого я сохраняю выбранный пользователем файл в отдельную папку, относительный путь до которой известен. Далее работа ведётся непосредственно с этим файлом.
- Принимаются только файлы формата .csv. Пользователю нужно отдельно загрузить обучающий файл без целевой переменной и файл со значениями целевой переменной.
- Настраивать можно следующие параметры:
  - количество деревьев
  - размер признакового пространства деревьев (можно установить по умолчанию: берётся $d//3$, где d - кол-во всех признаков)
  - глубина деревьев (можно не ограничивать)
  - $learning\_rate$ для градиентного бустинга. Для удобства пользователя его можно выбирать только кратным 0.01 из отрезка [0.01; 1]
- После обучения выводится информация о модели: гиперпараметры и значение функции потерь на каждой итерации
- Есть возможность загрузить файл и скачать предсказание по нему. На компьютер пользователя скачивается .csv файл с названием prediction, в котором два столбца: с индексом и со значением целевой переменной.

Важное замечание: сервер автоматически убирает категориальные признаки, имеющие формат, отличный от int, float. Это сделано по той причине, что пользователь не имеет возможности изменить способ кодирования категориальных признаков. Стало быть, программа не должна решать за него.